

Memo pour l'année

LAURENT Thomas

Master 2 informatique 2018

# Contents

<b>I</b>	<b>Fouille de donnée</b>	<b>1</b>
<b>1</b>	<b>Rappel sur les probabilités</b>	<b>2</b>
<b>2</b>	<b>Pré traitement des données</b>	<b>3</b>
2.1	Nettoyage des données . . . . .	3
2.1.1	Caractéristiques descriptives . . . . .	3
2.2	Normalisation . . . . .	3
<b>3</b>	<b>Classification</b>	<b>5</b>
3.1	Évaluation des classifieurs . . . . .	5
3.1.1	Matrice de confusion . . . . .	5
<b>4</b>	<b>Arbre de décision</b>	<b>6</b>
4.1	critères de sélection C4.5 . . . . .	6
4.1.1	Entropie . . . . .	7
4.2	critères d'arrêt . . . . .	8
4.2.1	Critères d'arrêt . . . . .	8
4.2.2	critères d'arrêt: Paramètre utilisateur . . . . .	9
4.3	Élagage . . . . .	9
<b>5</b>	<b>Classificateur bayésiens</b>	<b>10</b>
<b>II</b>	<b>Apprentissage par le pratique</b>	<b>11</b>
<b>6</b>	<b>Rappel</b>	<b>12</b>
6.1	Matrices et calculs sur les Matrices . . . . .	12
6.1.1	Addition . . . . .	12
6.1.2	Multiplication . . . . .	12

6.1.3	Transposer . . . . .	12
6.1.4	Inverse . . . . .	12
<b>7</b>	<b>Algorithms Learn a Mapping From Input to Output</b>	<b>14</b>
7.1	linear ML algorithms . . . . .	14
7.2	Supervised machine learning . . . . .	14
7.3	Unsupervised machine learning . . . . .	14
7.4	semi-supervised machine learning . . . . .	15
7.5	Overview of bias and variance . . . . .	15
<b>8</b>	<b>Overfitting and Underfitting</b>	<b>16</b>
8.1	Overfitting . . . . .	16
8.2	Underfitting . . . . .	16
<b>9</b>	<b>Linear Algorithms</b>	<b>17</b>
9.1	Régression linéaire . . . . .	17
9.2	Least squares linear regression . . . . .	19
9.3	Gradient Descent . . . . .	20
<b>10</b>	<b>Logistic Regression</b>	<b>21</b>
10.1	Logistic function . . . . .	21
10.2	Linear Discriminant Analysis . . . . .	21
10.2.1	la règle bayésienne . . . . .	22
<b>III</b>	<b>Outils formel</b>	<b>23</b>
<b>11</b>	<b>Logique classique des propositions</b>	<b>24</b>
11.1	Vocabulaire . . . . .	24
11.2	Propriétés de l'opérateur Models . . . . .	25
11.3	Ensemble de connecteurs fonctionnellement complet . . . . .	26
11.4	Preuve par induction structurelle sur un ensemble de connecteurs non fonctionnellement complet . . . . .	26
11.5	Décomposition de Shannon . . . . .	27
11.6	Arbre de Shannon, ROBDD . . . . .	28
11.6.1	Remplacement ou vérifonctionnalité . . . . .	28
11.6.2	Substitution . . . . .	28
11.7	Notion de impliquant premier . . . . .	29
11.7.1	Table de Karnaugh . . . . .	29

11.7.2	Calcul arithmétique . . . . .	29
11.8	Système de Hilbertien . . . . .	30
11.9	Forte complétude OU théorème de finitude . . . . .	30
<b>IV</b>	<b>Recherche Opérationnel</b>	<b>31</b>
<b>12</b>	<b>Rappel</b>	<b>32</b>
12.1	Pivot de gauss . . . . .	32
<b>13</b>	<b>Introduction à la PL</b>	<b>33</b>
13.1	Modèle linéaire continu à 2 variables . . . . .	33
13.1.1	Recherche de solutions . . . . .	34
13.1.2	recherche de la solution optimal . . . . .	34
<b>14</b>	<b>Le simplexe</b>	<b>36</b>
14.1	Initialisation du simplexe . . . . .	36
14.2	Canonicité du modèle . . . . .	37
14.3	Premier itération . . . . .	37
14.3.1	Choix de la variable entrante . . . . .	37
14.3.2	Choix de la variable sortante . . . . .	37
14.3.3	pivotage . . . . .	38
14.3.4	Nouveau modèle . . . . .	39
<b>15</b>	<b>Représentation des connaissances et raisonnement</b>	<b>40</b>
<b>16</b>	<b>XML</b>	<b>42</b>

# Part I

## Fouille de donnée

# Chapter 1

## Rappel sur les probabilités

**Quelques rappels de probabilités** : Soient X et Y deux variables aléatoires discrètes prenant leurs valeurs dans  $DX=x_1, \dots, x_n$  et  $DY=y_1, \dots, y_m$  respectivement.

$$P(x_i) = \frac{|x_i|}{\sum_{j=1}^n |x_j|}$$

$$\sum_{i=1}^n P(x_i) = 1$$

$$P(x_i|y_i) = \frac{P(x_i, y_i)}{p(y_i)}$$

$$P(x_i, y_i) = p(x_i) * p(y_i) \text{ Si X et Y sont indépendantes}$$

$$\text{r\`egle de chainage } P(x_1, x_2, x_3, \dots, x_n) = p(x_1) * p(x_2|x_1) * \dots * p(x_n|x_{n-1} \dots x_1)$$

$$\text{distribution conditionnel } \forall x \text{ in } X, \forall y \text{ in } Y \Rightarrow P(x|y)$$

Exemple:

$$: \begin{pmatrix} Anne & Sexe & \# & \% \\ M1 & M & 25 & 25/55 \\ M1 & F & 4 & 4/55 \\ M2 & M & 25 & 25/55 \\ M2 & F & 1 & 1/55 \end{pmatrix}$$

$$P(sexe = M) = P(Sexe = MetAnne = M1) + P(Sexe = MetAnne = M2) = 50/55$$

$$P(Anne = M2 | sexe = M) = P(Sexe = MetAnne = M2) / P(Sexe = M) = \frac{25}{55} / \frac{50}{55} = \frac{25}{50} = \frac{1}{2}$$

# Chapter 2

## Pré traitement des données

### 2.1 Nettoyage des données

#### 2.1.1 Caractéristiques descriptives

Objectifs: Résumer, décrire certains aspects (tendances, variation, dispersion...) des données en utilisant certaines mesures :

**Moyenne (espérance)** :  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

**Ecart moyen** :  $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$

**Variance** :  $v = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

**Ecart type** :  $\sigma_x := \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} = \sqrt{\frac{1}{n} (\sum_{i=1}^n x_i^2) - \bar{x}^2}$

**Médiane** : Valeur se trouvant au milieu d'une série de données ordonnées

**Mode** : Valeur la plus fréquente

**Amplitude** : min, max

### 2.2 Normalisation

**Min-max** :  $v_n = \frac{v - v_{min}}{v_{max} - v_{min}}$

**Min-max dans l'intervalle [A,B]** :  $v_n = \frac{v - v_{min}}{v_{max} - v_{min}} * (B - A) + A$

**Z-Score** :  $v_n = \frac{v - \text{moyenne}}{\text{ecart}_{type}}$

**Decimal scaling** :  $v_n = \frac{v}{100^j}$



# Chapter 3

## Classification

### 3.1 Évaluation des classifieurs

#### 3.1.1 Matrice de confusion

**Percent of correct classification :**

$$\text{PCC}(\%) = \frac{N_c}{N_t} * 100$$

$N_c$  : nombre d'instances correctement classées

$N_t$  : nombre d'instances testées ( $N_t = |D_{test}|$ )

Exemple:

$$: \begin{pmatrix} - & c1 & c2 & c3 & c4 \\ c1 & 0 & 1 & 0 & 0 \\ c2 & 1 & 60 & 0 & 1 \\ c3 & 0 & 1 & 23 & 0 \\ c4 & 1 & 0 & 7 & 5 \end{pmatrix}$$

**Taux d'erreurs :** 100-PCC

$$\text{PCC}(\%) = \frac{0+60+23+5}{100} * 100 = 88\%$$

# Chapter 4

## Arbre de décision

### 4.1 critères de sélection C4.5

Construction d'un arbre de décision C4.5 La construction d'un arbre de décision avec C4.5 passe par deux phases:

**Phase d'expansion** : La construction se fait selon l'approche descendante et laisse croître l'arbre jusqu'à sa taille maximale.

**Phase d'élagage** : Pour optimiser la taille l'arbre et son pouvoir de généralisation, C4.5 procède à l'élagage (pour supprimer les sous-arbres qui ne minimisent pas le taux d'erreurs)

**Approche de construction d'un AD** : Partitionner récursivement les données en sous-ensembles plus homogènes ... jusqu'à obtenir des partitions qui contiennent des objets qui appartiennent majoritairement à la même classe.

=> Théorie de l'information pour caractériser le degré de mélange, homogénéité, impureté, incertitude...

**Théorie de l'information** : Théorie mathématique ayant pour objet l'étude du contenu informationnel d'un message.  
Applications en codage, compression, sécurité...

**Entropie** : Mesure la quantité d'incertitude dans une distribution de probabilités.

### 4.1.1 Entropie

**Entropie** : Mesure la quantité d'incertitude (manque d'information) dans une distribution de probabilités. Soit  $X$  une variable aléatoire discrète prenant ses valeurs dans  $DX = x_1, \dots, x_n$ . Soit  $P$  la distribution de probabilités associée à  $X$ .

$$H(X) = - \sum_{i=1}^n p(x_i) * \log_2(p(x_i))$$

Par convention, quand  $p(x) = 0, 0 * \log(0) = 0$

Exemple:

X	P(X)
x_1	1/3
x_2	1/3
x_3	1/3

$$H(X) = -p(x_1) * \log_2(p(x_1)) - p(x_2) * \log_2(p(x_2)) - p(x_3) * \log_2(p(x_3))$$

$$H(X) = -3(\frac{1}{3} * \log_2(\frac{1}{3})) = \log_2(3) = 1.58$$

Autre exemples:

$$[\frac{1}{2}, \frac{1}{4}, \frac{1}{4}] : H(X) = 1.5$$

$$[1, 0, 0] : H(X) = 0$$

$$[\frac{1}{2}, \frac{1}{2}] : H(X) = 1$$

Propriétés:

$$H(X) \geq 0$$

$H(X)$  est maximale pour une distribution uniforme (toutes les valeurs sont équiprobables).

**Entropie conjointe** : L'entropie conjointe de deux variables aléatoires  $X$  et  $Y$  est l'incertitude relative à ces deux variables conjointement.

$$H(X, Y) = - \sum_{i,j=1}^n p(x_i, y_j) * \log_2(p(x_i, y_j))$$

**Exemple** :  $[0.2, 0.1, 0.3, 0.4] : H(X, Y) = 1.85$

Critère de sélection: Gain d'information:

$$GAIN(T, A) = Info(T) - Info(T|A)$$

**Avec**  $Info(T)$  : Entropie au niveau de T (avant de partitionner)

$$Info(T) = - \sum_{c_i} freq(c_i, T) * \log_2(freq(c_i, T))$$

$$\textbf{Avec } freq(c_i, T) = p(c_i) = \frac{|c_i|}{|T|}$$

**Avec**  $Info(T|A)$  l'entropie conditionnelle de T une fois partitionné selon les valeurs de l'attribut A.

$$Info(T|A) = \sum_{a_j \in A} freq(a_j, T) * Info(T|a_j)$$

Critère de sélection: Gain Ration:

Le gain d'information favorise les attributs ayant de larges domaines.

Le ratio de gain utilise le gain d'information avec un facteur pénalisant les attributs ayant des domaines trop larges.

$$GainRatio(T, A) = \frac{Gain(T, A)}{SplitInfo(T, A)}$$

**Avec**  $SplitInfo(T, A) = - \sum_{a_j \in A} freq(a_j, T) * \log_2(freq(a_j, T))$  = Entropie de A.

## 4.2 critères d'arrêt

### 4.2.1 Critères d'arrêt

Si tout les objets d'une partition appartiennent à une même classes

Si il n'y a plus aucun attributs à tester

si le nœud est vide (càd feuille de l'arbre)

Absence d'apport informationnel (le grain est négatif ou nul)

### **4.2.2 critères d'arrêt: Paramètre utilisateur**

Nombre d'objets minimum par feuille

Taille, profondeur de l'arbre

Temps de construction de l'arbre

## **4.3 Élagage**

L'élagage vient diminuer la longueur de l'arbre:

## Chapter 5

### Classificateur bayésiens

## Part II

# Apprentissage par le pratique

# Chapter 6

## Rappel

### 6.1 Matrices et calculs sur les Matrices

#### 6.1.1 Addition

$$\begin{pmatrix} 1 & 3 \\ 1 & 0 \\ 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 7 & 5 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 1+0 & 3+0 \\ 1+7 & 0+5 \\ 1+2 & 2+1 \end{pmatrix} = \begin{pmatrix} 1 & 3 \\ 8 & 5 \\ 3 & 3 \end{pmatrix}$$

#### 6.1.2 Multiplication

$$\begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$
$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$
$$(1 * 5) + (2 * 7) = 19$$

#### 6.1.3 Transposer

$$\begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}$$

#### 6.1.4 Inverse

Soit une matrice 2x2 comme :  $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$



Soit Determinant  $D = ad - bc$

Si  $D \neq 0$  alors il existe une matrice inverse égal à :  $\frac{1}{D} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$

# Chapter 7

## Algorithms Learn a Mapping From Input to Output

### 7.1 linear ML algorithms

Simplifier les processus d'apprentissage et réduire la fonction sur ce qu'on connaît

**Soit** :  $B_0 + B_1X_1 + B_2X_2 + B_3X_3 = 0$

Où  $B_0, B_1, B_2, B_3$  sont les coefficients présent sur l'axe des ordonnées.

Et  $X_1, X_2, X_3$  sont les valeurs en Input.

### 7.2 Supervised machine learning

L'apprentissage supervisé peut se diviser en 2 partis

**Classification** : Quand les variables en sortie sont des Classe (*Vert, Carr, Homme*)

**Regression** : Quand les variables en sortie sont des valeur numérique (*euro, poids, quantités*)

### 7.3 Unsupervised machine learning

Les problèmes de l'apprentissage non supervisé sont:

**Clustering** : L'art de faire des paquet d'éléments qui ont des points commun, comme regrouper les clients par paquet de choses qu'ils ont le plus en commun.

**Association** : Associer des règles d'apprentissage pour décrire une portion du data, comme une personne qui a acheté un item A et qui est aussi tenté par acheter un item B

## 7.4 semi-supervised machine leaning

L'apprentissage semi supervisé c'est avoir un bonne quantité de données en input X, et un peu de data avec le label Y.

## 7.5 Overview of bias and variance

La prédiction des erreurs pour les algorithmes sont regroupé en 3 points:

**Bias Error** : Simplifier l'hypothèse fait par le modèles pour faire une fonction d'apprentissage plus facile.

**Variance Error** : Et la quantité estimé par la fonction visé qui changera via un différent ensemble de data utilisé.

**Irreducible Error** : Ne peut pas être réduit

# Chapter 8

## Overfitting and Underfitting

### 8.1 Overfitting

L'overfitting intervient lorsque le modèle sur apprend des connaissances, Lorsque l'on sur apprend nous prenons en compte les points plus éloigné de la droite de la fonction.

On peut illustrer l'overfitting en codant un algorithme qui prend en compte les points bleu et rouges de la figure *ap-linear-regression\_1* ce dessous.

### 8.2 Underfitting

C'est l'inverse de l'overfitting, pas assez de données pour pouvoir généraliser le base de connaissance.


# Chapter 9

## Linear Algorithms

Soit  $X$  l'ensemble des variables indépendantes sur l'axe des l'abscisse et  $Y$  l'ensemble des variable dépendantes sur l'axe des ordonnée.

### 9.1 Régression linéaire

Étant donné un plan à deux dimensions où l'abscisse contient les point d'entrée  $X$  et l'ordonnée contient les points de sortie  $Y$ , et un nouage de points précédait acquitté de tout point éloigné du nuage.



*Figureap – linear – regression<sub>1</sub>*

Avec :  $y = \beta_0 + \beta_1 x$

**Pour un hyperPlan (3d) :**  $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$

$P - I_n$  :  $y = \beta_0 + \beta_1 x_1 + \dots \beta_n x_n$

Exemple:

$$\mathbf{5} = \beta_0 + 2 * \beta_1$$

$$\mathbf{2} = \beta_0 + 1 * \beta_1$$

## 9.2 Least squares linear regression

Calculer la régression linéaire avec la méthode Least squares:  
Soit:

$\mathbf{X} = [1, 2, 3, 4, 5]$  les variables indépendantes d'axe abscisse

$\mathbf{Y} = [2, 4, 5, 4, 5]$  les variables dépendantes d'axe ordonnée

**Calculons**  $y = \beta_0 + \beta_1 x$

Calcule de la moyenne de X et Y:

$$\mathbf{Xm} = \sum x_i \in X = 3$$

$$\mathbf{Ym} = \sum y_i \in Y = 4$$

Toutes ligne de régression doivent passer par le point (Xm,Ym).  
Calculer tout les écarts des  $x_i \in X$  par rapport à Xm (resp Y):

X	Y	$X - Xm$	$Y - Ym$	$(X - Xm)^2$	$(X - Xm)(Y - Ym)$
1	2	-2	-2	4	4
2	4	-1	0	1	0
3	5	0	1	0	0
4	4	1	0	1	0
5	5	2	1	4	2

Calculer  $\beta_1$  :

$$\beta_1 = \frac{\sum (X - Xm)(Y - Ym)}{\sum (X - Xm)^2} = \frac{6}{10} = .6$$

$$\beta_0 : Ym = \beta_0 + \beta_1 * Xm : 4 = \beta_0 + .6 * 3 : 4 = \beta_0 + 1.8 : \beta_0 = 2.2$$

## 9.3 Gradient Descent

Soit:

$$\mathbf{X} = [1, 2, 4, 3, 5]$$

$$\mathbf{Y} = [1, 3, 3, 2, 5]$$

$i$  = une variable qui itère les éléments de X et Y en bouclant à l'infini.

Une initialisation comme:

$$\beta_0 = 0$$

$$\beta_1 = 0$$

$\alpha$  = donnée en énoncé (pour l'exemple égal à 0.01)

Et des fonctions définit tel que:

$$\mathbf{error} = (\beta_0 + \beta_1 * X[i]) - Y[i]$$

$$\beta_{0+1} = \beta_0 - \alpha * error$$

$$\beta_{1+1} = \beta_1 - \alpha * error * X[i]$$

En appliquant l'algorithme des calculs des  $\beta_i$ :

$i$	$X[i]$	$Y[i]$	$error$	$\beta_0$	$\beta_1$
0	1	1	-1	0.01	0.01
1	2	3	-2.97	0.06	0.03
2	4	3	-1.77	0.18	0.06
3	3	2	-1.61	0.22	0.08
4	5	5	-4.35	0.44	0.12
0	1	1	-0.42	0.45	0.13
1	2	3	-2.28	0.49	0.49



# Chapter 10

## Logistic Regression

### 10.1 Logistic function

Soit:

$$t \in \mathbb{R}[0, 1] \text{ égal à } \beta_0 + \beta_2 * x$$

La fonction de logique de régression, les valeur d'entrée  $X$  sont combiné en utilisant les coefficient de valeur pour prédire une sortie  $Y$ . Cette sortie sera une valeur binaire.

$$p(x) = \frac{1}{1+e^{-(\beta_0 + \beta_1 x)}}$$

**Note :**  $p(x)$  peut être interprété comme une fonction de probabilité  $P(X) = P[Y = 1|X]$ .

$$\beta_0 + \beta_1 * x = \ln\left(\frac{P(x)}{1-P(x)}\right) \text{ aussi appelé odds.}$$

### 10.2 Linear Discriminant Analysis

L'analyse discriminante linéaire fait partie des techniques d'analyse discriminante prédictive, il s'agit de prédire l'appartenance d'un individu à une classe prédéfinie à partir de ses caractéristiques mesurées à l'aide de variables prédictives.

A notre disposition, un échantillon de  $n$  observations réparties dans  $k$  groupes d'effectifs  $n_k$ .

**Noté**  $Y$  les variables prédire  $\{y_1, \dots, y_k\}$

$J$  variables prédictives  $X = (X_1, \dots, X_j)$

$\mu_k$  la moyenne (ou *mean* en anglais) valant  $\lambda(list) - > \frac{\sum list[i]}{taille(list)}$

$\sigma^2$  la variance de toutes les classes  $\frac{\sum_{i=1}^n (x_i - \mu_k)^2}{n - k}$

**la fonction discriminante pour la classe  $k$  avec  $x$  donné**  $D_k(x) = x * \frac{\mu_k}{\omega^2} - \frac{\mu_k^2}{2x\omega^2} + \ln(P(k))$

Où  $P(k)$  vaut la probabilité appliqué aux valeurs de  $Y$

### 10.2.1 la règles bayésienne

L'objectif est de produire une règle d'affectation  $X(\omega) \rightarrow Y(\omega)$  qui permet de prédire, pour une observation  $\omega$  donné, sa valeur associé de  $Y$  à partir des valeurs prises par  $X$ . via une probabilité

$$P(Y = y_k) = \frac{P(Y=y_k) * P(X|Y=y_k)}{\sum_{i=1}^k P(Y=y_i) * P(X|Y=y_i)}$$

Où  $P(Y = y_k)$  est la probabilité à *priori* d'appartenance à une classe

$P(X|Y = y_k)$  représente la fonction de densité des  $X$  conditionnellement à la classe  $y_k$

# Part III

## Outils formel

# Chapter 11

## Logique classique des propositions

### 11.1 Vocabulaire

**Déduction**  $\models \alpha$  ssi  $\neg \alpha$  est contradictoire

**Absurde**  $\phi$  est contradictoire ssi  $\neg \phi$  est valide

**DAG** : Un graphe dirigé acyclique

**Taille(Arbre)** =  $\{\text{tout les symboles} + \text{connecteurs}\}$

**Var(Arbre)** =  $\{\text{Toutes les feuilles}\}$

**Sous formules(Arbres)** =  $\{T + \cup_{i=0}^k \text{SousFormules}(\text{Arbre}_i)\}$

**Interprétation** :  $\omega$  de  $PROP_{ps}$  est une application de PS dans 0.1

**Sémantique** :  $[[\phi]](\omega)$  d'une formule  $\phi$  de  $PROP_{ps}$  dans l'interprétation  $\omega$  est un élément de 0.1 défini inductivement par:

si  $\phi \in PS$  alors  $[[\phi]](\omega) = \omega(\phi)$

si  $\phi = cX_1 \dots X_n$  alors  $[[\phi]](\omega) = C_F([x_1]](\omega) \dots [x_n]](\omega))$

$\omega$  **satisfait**  $\phi$  noté  $\omega \models \phi$  ssi  $[[\phi]](\omega) = 1$

**Lorsque**  $\omega \models \phi$  on dit que  $\omega$  est un modèle de  $\phi$

**on note**  $\eta(\phi)$  l'ensemble des modèles de  $\phi$

$\omega \in PROP_{ps}$  est **valide** noté  $\models \phi$ , ssi toute interprétation  $\omega$  de  $PROP_{ps}$  satisfait  $\phi$

$\phi \equiv \psi$  sont logiquement équivalents ssi  $\phi \models \psi$  et  $\psi \models \phi$

## 11.2 Propriétés de l'opérateur Models


$a \models b \iff M(a) \subseteq M(b)$

**Réflexivité** :  $\phi \models \phi$


**Équivalence à gauche** : si  $\phi \equiv \theta$  et  $\phi \models \psi$  alors  $\theta \models \psi$

**Affaiblissement à droite (transitivité)** : si  $\phi \models \psi$  et  $\psi \models \theta$  alors  $\phi \models \theta$


**Coupure** : si  $\phi \wedge \psi \models \theta$  et  $\phi \models \psi$  alors  $\phi \models \theta$  :  $\iff (A \cup B) \subseteq C$  ssi  $A \subseteq C \cap B \subseteq C$



**Ou** :  $\phi \vee \psi \models \theta$  ssi  $\phi \models \theta$  et  $\psi \models \theta$



**Monotonie** : si  $\phi \models \theta$  alors  $\phi \wedge \psi \models \theta$



## 11.3 Ensemble de connecteurs fonctionnellement complet

**On dit qu'un ensemble est fonctionnellement complet** si avec que les connecteurs de cette ensemble on peut exprimer toutes les formules d'un monde.

$\{\neg, \wedge\}$  est fonctionnellement complet pour la logique propositionnel classique

Il en va de même pour  $\{\neg, \vee\}, \{vrai, \wedge, \oplus\}, \{\neg, \Rightarrow\}$  ou  $\{NAND\}$

**Suppression des fils équivalent** : Soit un arbre D ayant comme sous arbre plus d'une fois le nœud  $\alpha = (\top X \top)$ ,  $\alpha$  peut être remplacé par  $(\top)$  tout en concevant les modèles de D.

**fusion des nœuds** : Soit un arbre D ayant comme sous arbre les nœuds  $(aBc)$  et  $(a'B'c')$  et  $a = a', b = b', c = c'$  alors on peut faire relier les deux branches menant vers ces nœuds vers le même sous arbre.

## 11.4 Preuve par induction structurelle sur un ensemble de connecteurs non fonctionnellement complet

Soit  $\forall P \in \{\wedge, \vee\}_{ps}$ , vérifier P:

**Cas de base**  $\varphi \in PS$  :  $1 \rightarrow (\varphi) = 1$  donc  $1 \rightarrow$  constitue un modèle de  $\varphi$

**Étape inductive** :

$\varphi$  s'écrit :  $[\alpha \wedge \beta]$  ou  $[\alpha \vee \beta]$

Avec  $\alpha, \beta \in \{\wedge, \vee\}_{ps}$

Par hypothèse d'induction,  $\alpha$  et  $\beta$  vérifient P.

Il ne reste plus qu'à montrer que  $\varphi$  vérifie P.

$$[[\alpha \vee \beta]](1 \rightarrow) = \vee \models ([[ \alpha ]](1 \rightarrow), [[ \beta ]](1 \rightarrow)) = \vee \models (1, 1) = 1$$

$$[[\alpha \wedge \beta]](1 \rightarrow) = \wedge \models ([[ \alpha ]](1 \rightarrow), [[ \beta ]](1 \rightarrow)) = \wedge \models (1, 1) = 1$$

donc  $x \wedge \neg x$  ne vérifie pas P :  $[[x \wedge \neg x]](1 \rightarrow) = 0$

## 11.5 Décomposition de Shannon

**On note**  $\phi[x \leftarrow 0]$  la formule obtenue en substituant dans  $\phi$  la constante faux à toutes les occurrences du symbole propositionnel  $x$ .


**On note**  $\phi[x \leftarrow 1]$  la formule obtenue en substituant dans  $\phi$  la constante vrai à toutes les occurrences du symbole propositionnel  $x$ .

La décomposition de Shannon de  $\phi$  suivant  $x$  est la formule:

$$(\neg x \wedge \phi[x \leftarrow 0]) \vee (x \wedge \phi[x \leftarrow 1])$$


## 11.6 Arbre de Shannon, ROBDD

Étant donnée un ordre strict total  $x_1 < x_2 < x_3$  sur  $Var(\phi) = \{x_1, \dots, x_n\}$   
 Et une formule  $\phi = (\neg x_1 \wedge x_2) \vee (\neg x_2 \wedge x_3)$



L'ensemble des modèles de  $\phi$  sont toutes les interprétation où la feuille vaut la valeur  $T$ .

### 11.6.1 Remplacement ou vérifonctionnalité



$\phi \equiv \phi'$  quelque soit la valeur de  $x$  (vrai ou faux).

### 11.6.2 Substitution

Soit un arbre  $D$  ayant comme nœud un sous arbre du type infixe  $\alpha = (x \Rightarrow y)$   
 et un sous arbre de substitution  $\beta = (\neg x \Rightarrow \neg y)$



$$(D' = D_{\alpha \leftarrow \beta} \equiv D)$$

## 11.7 Notion de impliquant premier

Les impliquant premier sont des sous formules des formules original tel que ces sous formules soit plus petite que la formule d'origine elle conserve les même modèles:

En circuit combinatoire les algo sont appelé Table de Karnaugh ou Quine-McCluskey.

### 11.7.1 Table de Karnaugh

Appliquer l'algorithme avec la formule  $S = \neg ab \neg cd + a \neg b \neg c \neg d + b \neg d$

S	$\neg a \neg b$	$\neg ab$	$ab$	$a \neg b$
$\neg c \neg d$	X	X	X	X
$\neg cd$		X	X	
$cd$		X	X	
$c \neg d$	X	X	X	X

les impliquant premier de S sont  $b \neg d$

### 11.7.2 Calcule arithmétique

En logique, les impliquant premier sont calculer que à partir d'une formule en mode CNF transposé en DNF et ensuite détransposé en CNF.

$$\phi = (a \wedge b \wedge c) \vee (\neg b \wedge c)$$

$$\phi = (a \vee \neg b) \wedge (a \vee c) \wedge (b \vee \neg b) \wedge (b \vee c) \wedge (c \vee \neg b) \wedge (c \vee c)$$

$$\phi = (a \vee \neg b) \wedge (a \vee c) \wedge (b \vee c) \wedge (c \vee \neg b) \wedge c$$

$$\phi = (a \vee \neg b) \wedge c$$

$$\phi = (a \wedge c) \vee (\neg b \wedge c) \text{ sont les impliquant premier.}$$

Via une table de Karnaugh:

$\phi$	$\neg a \neg b$	$\neg ab$	$ab$	$a \neg b$
$\neg c$				
$c$	X		X	X

Égal à  $(a \wedge c) \vee (\neg b \wedge c)$ .

## 11.8 Système de Hilbertien

gg

## 11.9 Forte complétude OU théorème de finitude

g

# Part IV

## Recherche Opérationnel

# Chapter 12

## Rappel

### 12.1 Pivot de gauss

$$L1 \text{ et } L2 = \begin{cases} L1 : 160 = 8x + 4y \\ L2 : 120 = 4x + 6y \end{cases}$$

$$(L2 * (-2)) = \begin{cases} L1 : 160 = 8x + 4y \\ L2 : -240 = -8x - 12y \end{cases}$$

$$(L2 = L2 + L1) = \begin{cases} L1 : 160 = 8x + 4y \\ L2 : -80 = -8y \end{cases}$$

$$y = 10$$

$$8x + 4 * 10 = 160$$

$$8x + 40 = 160$$

$$8x = 120$$

$$x = 15$$

# Chapter 13

## Introduction à la PL

Construire une modèle linéaire, c'est donc:

**identifier** les variables de décision du problème

**déterminer** : la fonction objectif du modèle

**déterminer** : les contraintes du modèle

### 13.1 Modèle linéaire continu à 2 variables

Soit le modèle linéaire suivantes:

**Déterminer**  $(x, y) \in \mathfrak{S}^2$

**Minimisant**  $z = 1000x + 1200y$

**sous les contraintes** :

$$(1) 8x + 4y \leq 160$$

$$(2) 4x + 6y \leq 120$$

$$(3) x \leq 34$$

$$(4) y \leq 14$$

$$(5) 0 \leq x$$


$$(6) 0 \leq y$$

### 13.1.1 Recherche de solutions

Après avoir tracé graphiquement tout les points:

Pour chaque contrainte, tracer la droite et repérer le demi plan des solution: exemple pour (5) et (6), x et y doivent être supérieurs ou égal à 0, d'où le demi plan des solution sont toutes les valeurs positives.

La partie En vert représente la région admissible, quelque soit le point choisis dans ce vert, aucune contrainte ne sera violé.



### 13.1.2 recherche de la solution optimal

Changer l'équation  $z$  tel que  $z$  soit égal à 0


$$z = 1000x + 1200y = 0 = 1000 * (1200) + 1200 * (-1000)$$

Traçons la droite  $(0, 0)$ ,  $(1200, -1000)$

**Un point extrême** : est un point se trouvant sur l'intersection de 2 contraintes et étant dans la zone admissible.

**L'altitude** : est la droite (rouge) la plus haute touchant un point extrême, ce point sera le vecteur  $(x, y)$  le plus optimal pour  $z$ .

Les droites rouges doivent être toutes parallèles.



Dans cet exemple le point  $(15,10)$  est le point extrême maximal pour l'équation  $z$ .

# Chapter 14

## Le simplexe

Soit le modèle linéaire suivantes:

**Déterminer**  $(x, y) \in \mathfrak{S}^2$

**Maximisant**  $Z = 3x + 7y$

**sous les contraintes :**

$$(1) -x + y \leq 3$$

$$(2) y \leq 8$$

$$(3) 2x - y \leq 28$$

$$(5) 0 \leq x$$

$$(6) 0 \leq y$$

### 14.1 Initialisation du simplexe

Pour chaque expression du type (1)(2)(3) intégrer un  $e_i$  pour la transformer en équation.

On appelle les  $e_1$  des variables d'accumulation, Ce qui fait

**Déterminer**  $(x, y, e_1, e_2, e_3) \in \mathfrak{S}^5$

**Maximisant**  $Z = 3x + 7y$

**sous les contraintes :**



$$(1) -x + y + e_1 = 3$$

$$(2) y + e_2 = 8$$

$$(3) 2x - y + e_3 = 28$$

$$(5) 0 \leq x$$

$$(6) 0 \leq y$$

$$(7) e_1, e_2, e_3 \geq 0$$

## 14.2 Canonicité du modèle

Soit les valeurs (pour la première itération)

**Hors Base**  $(x, y)$

**Base**  $(e_1, e_2, e_3)$

Un modèle est canonique que si:

**si toutes les variables de Base** ne sont pas dans  $Z$ .

## 14.3 Premier itération

### 14.3.1 Choix de la variable entrante

$(x, y)$  sont deux choix possible, le tout est de choisir une bonne heuristique, comme celle du meilleur gain marginale, ou via la comparaison (en mode graphique):

$Y$  sera choisit, donc  $Y$  sera notre variable entrante.

### 14.3.2 Choix de la variable sortante

Pour chaque résultat d'équation, le diviser par sa valeur de  $Y$  (car  $Y$  est la variable entrante)

$$-x + y + e_1 = 3 \text{ donne } \frac{3}{1} = 3 \text{ (1 car } y = 1 * y)$$

$$y + e_2 = 8 \text{ donne } \frac{8}{1} = 8$$

$$2x - y + e_3 = 28 \text{ donne } \frac{28}{1} = 28$$

Prendre le minimum des variables, donc se sera 3.  
la variable présente dans la Base sera prise comme variable sortante, dans notre cas  $e_1$ .

### 14.3.3 pivotage

On choisit l'équation associée à la variable  $e_1$  pour définir la variable entrante  $y$ .

On n'a:

$$y = x - e_1 + 3$$

Puis on crée les nouvelles équations via le nouveau  $y$ :

$$Z = 3x + 7y \text{ devient}$$

$$Z = 3x + 7(x - e_1 + 3)$$

$$Z = 10x - 7e_1 + 27$$

$$x - e_1 = 3 \text{ est déjà normalisé}$$

$$y + e_2 = 8 \text{ devient}$$

$$8 = x - e_1 + 3 + e_2$$

$$5 = x - e_1 + e_2$$

$$2x - y + e_3 = 28 \text{ devient}$$

$$28 = 2x + (x - e_1 + 3) + e_3$$

$$25 = 3x - e_1 + e_3$$

#### 14.3.4 Nouveau modèle

Après cette étape nous voilà avec un nouveau modèle:

**Déterminer**  $(x, y, e_1, e_2, e_3) \in \mathfrak{S}^5$

**Maximisant**  $Z = 10x - 7e_1 + 21$

**sous les contraintes :**

$$(1) -x + y + e_1 = 3$$

$$(2) x - e_1 + e_2 = 5$$

$$(3) 3x - e_1 + e_3 = 25$$

$$(5) 0 \leq x$$

$$(6) 0 \leq y$$

$$(7) e_1, e_2, e_3 \geq 0$$

A ne pas oublier de vérifier la canonicité du modèle.

## Chapter 15

### Représentation des connaissances et raisonnement

ggggg

# Chapter 16

## XML

uuuuu